

Nama: I Gede Suryananda Adikartika

Nim: 2201020038

Prodi: Teknik Informatika

Report & Insights

1. Executive Summary Hasil

Proyek ini bertujuan untuk membangun dan mengevaluasi model regresi yang optimal untuk memprediksi harga properti, dengan fokus utama pada analisis *Bias-Variance Trade-off*. Kami men-generate dataset sintetis non-linear (200 sampel, 5 fitur) dan menguji 35 konfigurasi model yang berbeda, membandingkan 5 tingkat kompleksitas (Polynomial Degree 1-5) dengan 3 metode regularisasi (Linear Regression, Ridge, dan Lasso).

Analisis perbandingan model secara jelas menunjukkan bahwa model Degree 1 mengalami *underfitting*, sementara model Degree 4 dan 5 mengalami *overfitting* yang parah (contoh: Test R² anjlok ke 0.000).

Model pemenang yang terpilih adalah Lasso (L1) Regression dengan Polynomial Degree 2 dan alpha=1.0. Model ini secara konsisten memberikan performa terbaik di seluruh pengujian, mencapai skor Test R² tertinggi (0.983) dan Test RMSE terendah. Model ini juga menunjukkan keseimbangan (balance) sempurna antara skor *train* dan *test*, yang membuktikan ia bebas dari *overfitting*. Model final ini telah divalidasi menggunakan K-Fold Cross-Validation dan disimpan untuk prediksi di masa depan.

2. Insight dari EDA

1. Data Preparation.

a. Data Generation

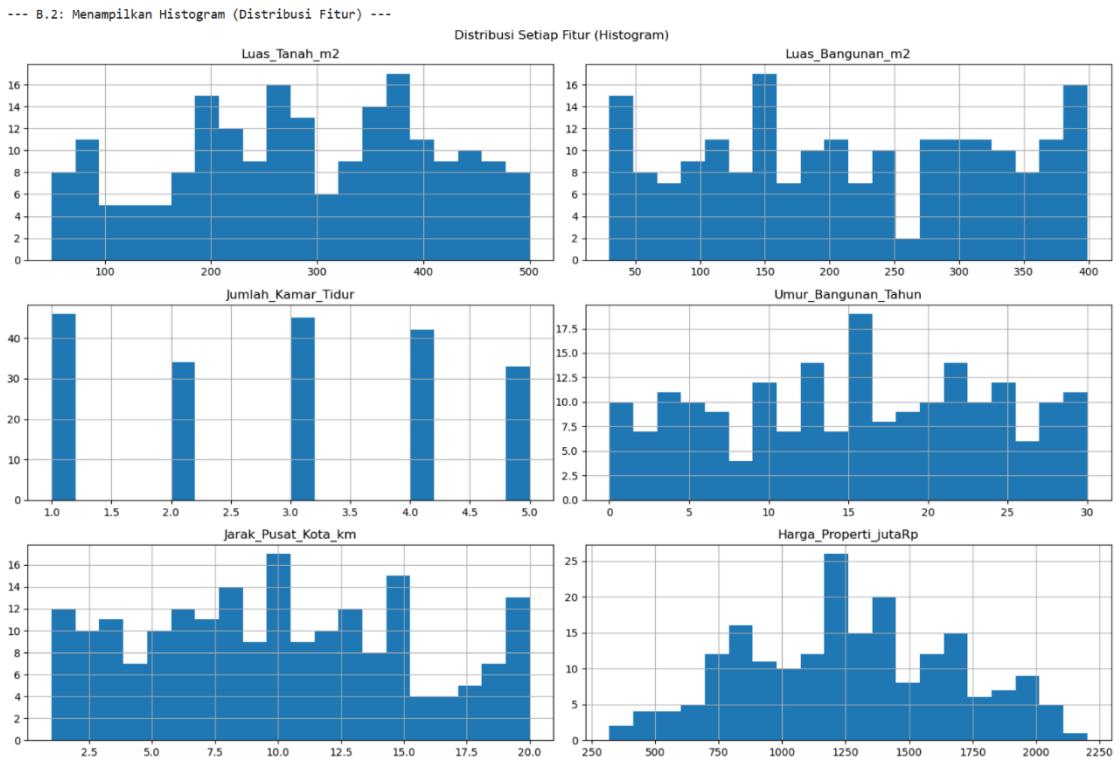
| | Luas_Tanah_m2 | Luas_Bangunan_m2 | Jumlah_Kamar_Tidur | Umur_Bangunan_Tahun | Jarak_Pusat_Kota_km | Harga_Properti_jutaRp |
|----|---------------|------------------|--------------------|---------------------|---------------------|-----------------------|
| 1 | 216 | 305 | 1 | 28 | 14 | 1171 |
| 2 | 360 | 63 | 1 | 15 | 7 | 954 |
| 3 | 491 | 33 | 5 | 14 | 10 | 1291 |
| 4 | 400 | 39 | 2 | 18 | 10 | 1047 |
| 5 | 243 | 185 | 3 | 13 | 10 | 973 |
| 6 | 404 | 228 | 3 | 1 | 4 | 1679 |
| 7 | 52 | 381 | 3 | 25 | 8 | 1230 |
| 8 | 295 | 260 | 2 | 27 | 13 | 1250 |
| 9 | 441 | 317 | 3 | 15 | 5 | 1856 |
| 10 | 107 | 129 | 5 | 3 | 6 | 738 |
| 11 | 394 | 148 | 3 | 7 | 4 | 1338 |
| 12 | 225 | 299 | 4 | 20 | 20 | 1369 |
| 13 | 341 | 391 | 2 | 6 | 9 | 1948 |
| 14 | 67 | 296 | 5 | 7 | 11 | 1168 |
| 15 | 109 | 167 | 4 | 19 | 15 | 818 |
| 16 | 262 | 69 | 1 | 17 | 6 | 732 |
| 17 | 214 | 383 | 4 | 24 | 10 | 1663 |
| 18 | 83 | 336 | 1 | 10 | 6 | 1202 |
| 19 | 228 | 261 | 5 | 16 | 18 | 1258 |
| 20 | 380 | 391 | 5 | 20 | 8 | 2020 |
| 21 | 336 | 367 | 4 | 0 | 5 | 1998 |
| 22 | 442 | 363 | 1 | 24 | 10 | 1936 |
| 23 | 377 | 368 | 1 | 9 | 2 | 1915 |
| 24 | 265 | 146 | 4 | 19 | 10 | 1071 |
| 25 | 239 | 295 | 1 | 10 | 14 | 1241 |
| 26 | 313 | 144 | 3 | 21 | 8 | 1160 |
| 27 | 193 | 34 | 1 | 8 | 4 | 432 |
| 28 | 443 | 234 | 3 | 5 | 15 | 1680 |
| 29 | 468 | 392 | 2 | 25 | 6 | 2102 |
| 30 | 361 | 179 | 3 | 28 | 13 | 1277 |

b. Exploratory Data Analysis

- Menampilkan statistic data sumary

| | Luas_Tanah_m2 | Luas_Bangunan_m2 | Jumlah_Kamar_Tidur | Umur_Bangunan_Tahun | Jarak_Pusat_Kota_km | Harga_Properti_jutaRp |
|-------|---------------|------------------|--------------------|---------------------|---------------------|-----------------------|
| count | 200.000 | 200.000 | 200.000 | 200.000 | 200.000 | 200.000 |
| mean | 287.340 | 216.260 | 2.910 | 15.175 | 9.910 | 1,268.375 |
| std | 122.153 | 111.852 | 1.401 | 8.587 | 5.579 | 412.484 |
| min | 50.000 | 30.000 | 1.000 | 0.000 | 1.000 | 320.000 |
| 25% | 198.000 | 122.250 | 2.000 | 8.000 | 5.750 | 957.000 |
| 50% | 288.000 | 204.500 | 3.000 | 15.000 | 10.000 | 1,250.500 |
| 75% | 383.250 | 316.000 | 4.000 | 22.000 | 14.000 | 1,591.500 |
| max | 500.000 | 399.000 | 5.000 | 30.000 | 20.000 | 2,202.000 |

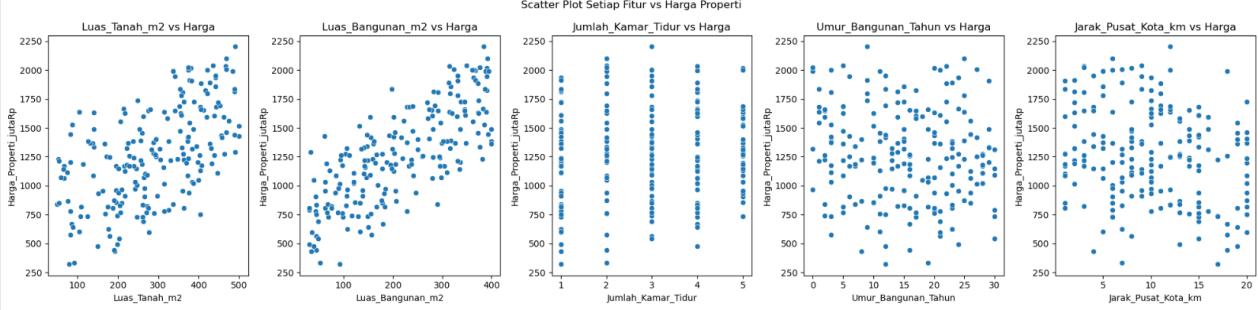
- Visualisasi distribusi setiap fitur (histogram)



Menunjukkan distribusi data dari beberapa fitur properti seperti luas tanah, luas bangunan, jumlah kamar, umur bangunan, jarak ke pusat kota, dan harga. Setiap grafik menampilkan seberapa banyak data (sumbu Y) yang memiliki nilai tertentu pada rentang fitur tersebut (sumbu X). Dari bentuk batangnya, kita bisa melihat pola sebaran data—apakah merata, terkonsentrasi di satu kisaran, atau memiliki variasi besar antar nilai.

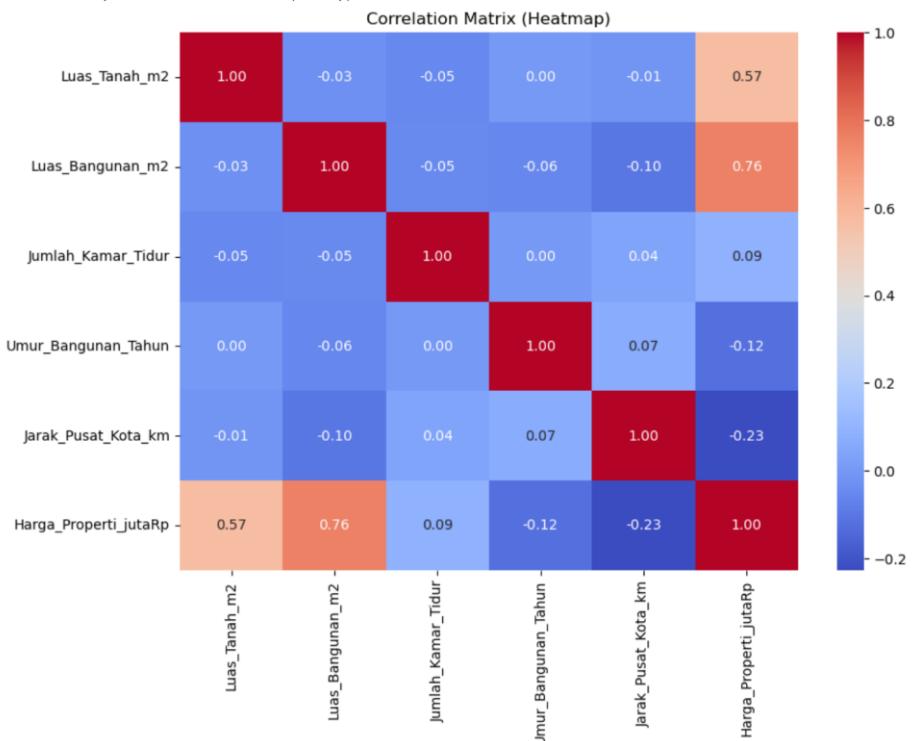
- Scatter plot setiap fitur vs harga

--- B.3: Menampilkan Scatter Plot (Fitur vs Harga) ---



Scatter plot antara setiap fitur dengan harga properti untuk melihat hubungan di antara keduanya. Titik-titik yang cenderung naik ke kanan (seperti pada *Luas Tanah* dan *Luas Bangunan*) menunjukkan bahwa semakin besar nilai fitur tersebut, harga properti juga cenderung meningkat. Sementara itu, pada fitur seperti *Umur Bangunan* dan *Jarak ke Pusat Kota*, pola titiknya lebih menyebar acak, menandakan hubungan yang lemah atau tidak terlalu berpengaruh terhadap harga.

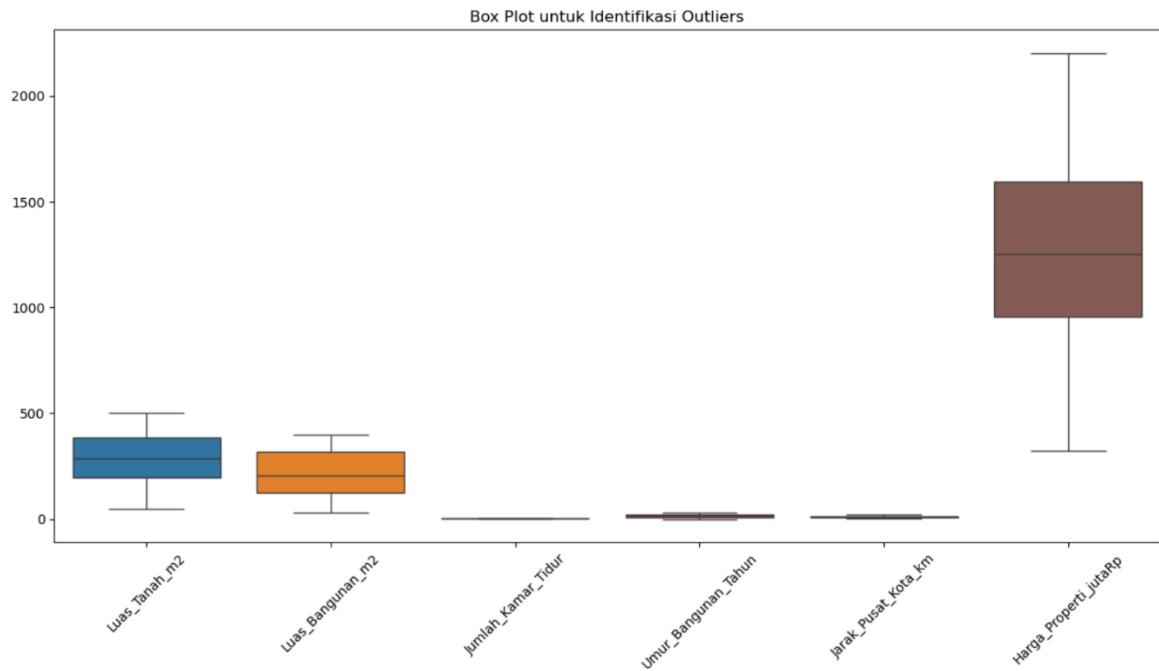
- Correlation matrix (heatmap)



Menunjukkan heatmap korelasi antar fitur dalam dataset, yang menggambarkan seberapa kuat hubungan antara satu variabel dengan variabel lainnya. Warna merah menandakan korelasi positif (semakin tinggi nilai satu variabel, semakin tinggi juga variabel lainnya), sedangkan biru menandakan korelasi negatif. Dari hasilnya, terlihat bahwa Luas Bangunan (0.76) dan Luas Tanah (0.57) memiliki korelasi paling kuat dengan Harga Properti, artinya kedua faktor tersebut paling berpengaruh terhadap tinggi rendahnya harga rumah.

- **Identifikasi Outlier**

--- B.5: Menampilkan Box Plot (Identifikasi Outliers) ---



Mengidentifikasi outlier atau data yang menyimpang jauh dari nilai umum pada setiap fitur. Kotak menunjukkan sebaran data utama (dari kuartil bawah ke atas), garis di tengah kotak menunjukkan median, dan titik di luar “garis whisker” menunjukkan kemungkinan data ekstrem (outlier). Dari grafik ini, terlihat bahwa sebagian besar fitur memiliki sebaran data yang cukup normal tanpa banyak outlier, sementara fitur Harga Properti memiliki rentang nilai yang lebih besar, menandakan variasi harga yang tinggi antar properti.

3. Perbandingan Performa Model

C. Data Preprocessing

- **Split data train-test (70:30)**

--- Split Data Train-Test (70:30) ---

Data dibagi:

```
X_train shape: (140, 5)
X_test shape: (60, 5)
y_train shape: (140,)
y_test shape: (60,)
```

=====

- Feature scaling menggunakan StandardScaler

```
Data X_train sebelum scaling (5 baris pertama):
  Luas_Tanah_m2  Luas_Bangunan_m2  Jumlah_Kamar_Tidur  Umur_Bangunan_Tahun  Jarak_Pusat_Kota_km
169           439            111                  2                28                   13
97            198             31                  1                24                   13
31            407             97                  4                3                    15
12            341            391                  2                6                     9
35             50             290                  1                7                   12

Data X_train SETELAH scaling (5 baris pertama):
[[ 1.1622201 -0.99556459 -0.58293911  1.55245217  0.51283808]
 [-0.70525805 -1.69640202 -1.29882925  1.07842097  0.51283808]
 [ 0.9142562 -1.11821114  0.84884117 -1.41024281  0.86478578]
 [ 0.40283065  1.4573664 -0.58293911 -1.05471941 -0.19105732]
 [-1.85209111  0.57255915 -1.29882925 -0.93621161  0.33686423]]
```

2. Model Implementation.

a. Polynomial Feature Engineering

Jumlah fitur dari setiap degree:

Degree 1: Menghasilkan 5 fitur
Degree 2: Menghasilkan 20 fitur
Degree 3: Menghasilkan 55 fitur
Degree 4: Menghasilkan 125 fitur
Degree 5: Menghasilkan 251 fitur

b. Model Training

Model training dengan 5 degree :

```
Melatih model untuk Degree 1...
Melatih model untuk Degree 2...
Melatih model untuk Degree 3...
Melatih model untuk Degree 4...
Melatih model untuk Degree 5...
--- Pelatihan Model Selesai ---
Semua 35 model telah dilatih dan disimpan dalam variabel 'trained_models'.

Contoh model yang tersimpan:
Model untuk Degree 2: ['LinearRegression', 'Ridge (alpha=0.1)', 'Ridge (alpha=1)', 'Ridge (alpha=10)', 'Lasso (alpha=0.1)', 'Lasso (alpha=1)', 'Lasso (alpha=10)']
Model untuk Degree 5: ['LinearRegression', 'Ridge (alpha=0.1)', 'Ridge (alpha=1)', 'Ridge (alpha=10)', 'Lasso (alpha=0.1)', 'Lasso (alpha=1)', 'Lasso (alpha=10)']
```

3. Model Evaluation.

Hasil evaluasi Metrics Calculation Untuk setiap model, hitung:

| Degree | Model | Train R2 | Test R2 | Train RMSE | Test RMSE | Train MAE | Test MAE |
|--------|---------------------|----------|---------|------------|-----------|-----------|----------|
| 12 | 2 Lasso (alpha=1) | 0.983 | 0.983 | 55.394 | 47.153 | 43.756 | 36.539 |
| 9 | 2 Ridge (alpha=1) | 0.983 | 0.983 | 55.299 | 47.617 | 44.003 | 36.321 |
| 11 | 2 Lasso (alpha=0.1) | 0.983 | 0.983 | 55.207 | 47.676 | 43.801 | 36.498 |
| 2 | 1 Ridge (alpha=1) | 0.981 | 0.983 | 59.157 | 47.703 | 47.523 | 39.475 |
| 8 | 2 Ridge (alpha=0.1) | 0.983 | 0.983 | 55.205 | 47.737 | 43.854 | 36.509 |
| 5 | 1 Lasso (alpha=1) | 0.981 | 0.983 | 59.119 | 47.745 | 47.349 | 39.297 |
| 7 | 2 LinearRegression | 0.983 | 0.983 | 55.204 | 47.761 | 43.842 | 36.530 |
| 13 | 2 Lasso (alpha=10) | 0.979 | 0.983 | 62.487 | 47.766 | 50.939 | 38.674 |
| 1 | 1 Ridge (alpha=0.1) | 0.981 | 0.982 | 59.078 | 48.096 | 47.169 | 39.410 |
| 4 | 1 Lasso (alpha=0.1) | 0.981 | 0.982 | 59.077 | 48.103 | 47.151 | 39.392 |
| 0 | 1 LinearRegression | 0.981 | 0.982 | 59.077 | 48.147 | 47.130 | 39.402 |
| 6 | 1 Lasso (alpha=10) | 0.978 | 0.982 | 63.120 | 48.316 | 51.408 | 39.520 |
| 3 | 1 Ridge (alpha=10) | 0.977 | 0.981 | 65.713 | 49.836 | 53.912 | 42.068 |
| 10 | 2 Ridge (alpha=10) | 0.979 | 0.978 | 62.787 | 54.083 | 51.785 | 41.407 |
| 19 | 3 Lasso (alpha=1) | 0.987 | 0.976 | 48.304 | 56.295 | 38.665 | 45.817 |
| 27 | 4 Lasso (alpha=10) | 0.978 | 0.973 | 63.252 | 59.742 | 52.137 | 47.759 |
| 20 | 3 Lasso (alpha=10) | 0.978 | 0.972 | 64.113 | 60.725 | 52.744 | 49.299 |
| 26 | 4 Lasso (alpha=1) | 0.992 | 0.971 | 38.715 | 61.400 | 29.823 | 49.321 |
| 18 | 3 Lasso (alpha=0.1) | 0.988 | 0.968 | 46.563 | 64.306 | 36.947 | 52.107 |
| 16 | 3 Ridge (alpha=1) | 0.988 | 0.967 | 47.872 | 65.548 | 38.450 | 52.592 |
| 15 | 3 Ridge (alpha=0.1) | 0.988 | 0.967 | 46.544 | 65.561 | 37.020 | 52.921 |
| 14 | 3 LinearRegression | 0.988 | 0.967 | 46.525 | 65.879 | 36.929 | 53.290 |
| 34 | 5 Lasso (alpha=10) | 0.978 | 0.965 | 64.001 | 67.449 | 51.212 | 52.121 |
| 33 | 5 Lasso (alpha=1) | 0.995 | 0.962 | 29.936 | 69.962 | 21.328 | 51.178 |
| 17 | 3 Ridge (alpha=10) | 0.975 | 0.945 | 67.670 | 84.657 | 52.499 | 66.673 |
| 24 | 4 Ridge (alpha=10) | 0.983 | 0.930 | 55.224 | 95.570 | 41.284 | 72.683 |
| 23 | 4 Ridge (alpha=1) | 0.995 | 0.925 | 28.863 | 98.827 | 21.660 | 82.621 |
| 25 | 4 Lasso (alpha=0.1) | 0.997 | 0.911 | 25.212 | 108.041 | 18.446 | 83.600 |
| 31 | 5 Ridge (alpha=10) | 0.992 | 0.882 | 38.626 | 124.240 | 22.886 | 89.888 |
| 22 | 4 Ridge (alpha=0.1) | 0.997 | 0.881 | 23.670 | 124.434 | 17.599 | 99.785 |
| 32 | 5 Lasso (alpha=0.1) | 1.000 | 0.862 | 8.661 | 134.192 | 4.747 | 87.232 |
| 21 | 4 LinearRegression | 0.997 | 0.821 | 23.302 | 153.014 | 17.162 | 118.382 |
| 30 | 5 Ridge (alpha=1) | 0.999 | 0.815 | 12.341 | 155.575 | 5.619 | 110.374 |
| 29 | 5 Ridge (alpha=0.1) | 1.000 | 0.697 | 2.873 | 198.794 | 1.089 | 140.602 |
| 28 | 5 LinearRegression | 1.000 | 0.642 | 0.000 | 216.284 | 0.000 | 151.826 |

--- Bagian 3.A Selesai ---

Hasil evaluasi lengkap juga disimpan ke 'model_evaluation_results.csv'

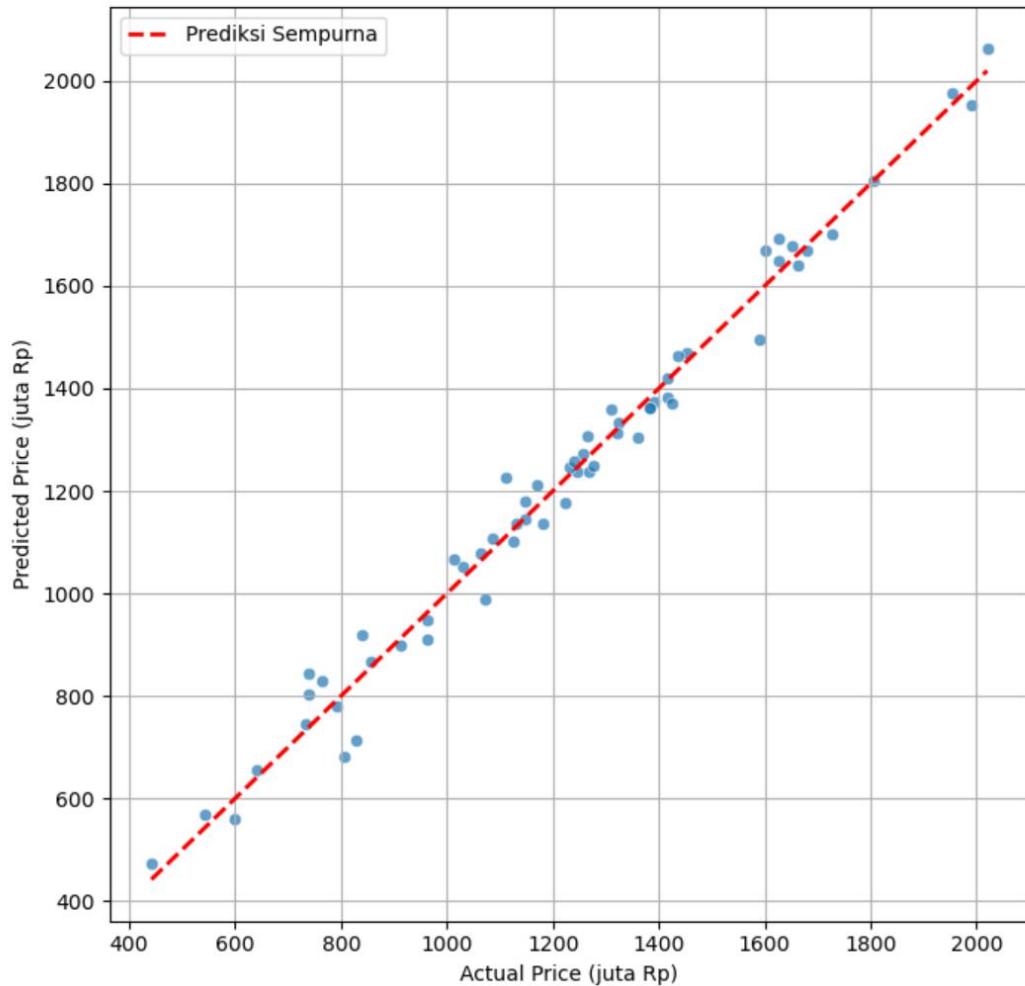
hasil evaluasi model regresi (Linear, Ridge, dan Lasso) dengan berbagai nilai *degree* dan parameter *alpha* untuk memprediksi harga properti. Kolom R² menunjukkan seberapa baik model menjelaskan variasi data (semakin mendekati 1 berarti semakin akurat), sedangkan RMSE dan MAE menunjukkan rata-rata besar kesalahan prediksi (semakin kecil semakin baik). Dari tabel terlihat bahwa model Lasso atau Ridge dengan degree rendah (1–2) memberikan performa terbaik, karena memiliki nilai R² tinggi serta error (RMSE dan MAE) yang relatif kecil di data uji.

Hasil Visualization:

- **Plot predicted vs actual values untuk test set**

Menampilkan Plot 1: Actual vs Predicted...

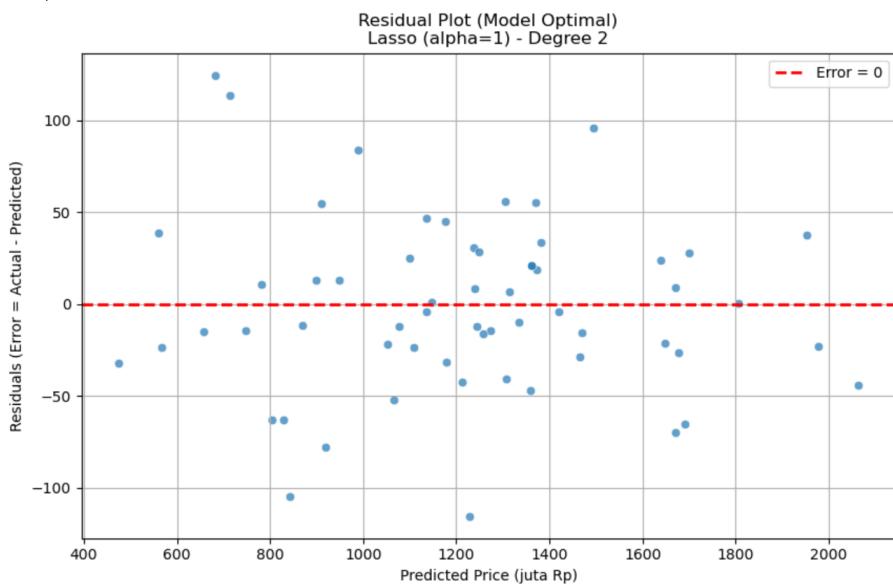
Actual vs. Predicted Values (Model Optimal)
Lasso (alpha=1) - Degree 2



Menunjukkan perbandingan antara harga aktual dan harga prediksi dari model terbaik, yaitu Lasso (alpha=1) dengan degree 2. Titik-titik biru mewakili hasil prediksi model, sedangkan garis merah putus-putus menunjukkan prediksi sempurna di mana nilai aktual dan prediksi sama persis. Karena sebagian besar titik berada sangat dekat dengan garis merah, berarti model ini memiliki akurasi tinggi dan mampu memprediksi harga properti dengan sangat baik.

- Residual plot untuk analisis error

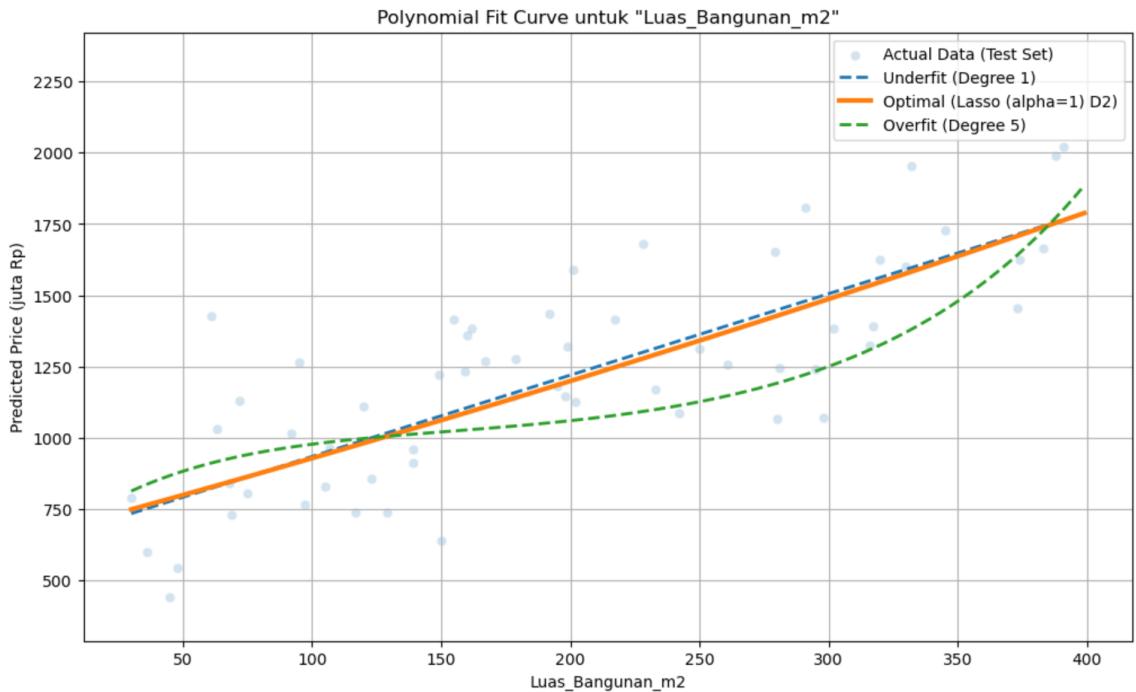
Menampilkan Plot 2: Residual Plot...



Residual plot dari model terbaik Lasso ($\alpha=1$, $\text{degree}=2$) yang menunjukkan selisih antara nilai aktual dan nilai prediksi. Titik-titik biru mewakili error (residual), sedangkan garis merah menunjukkan posisi $\text{error} = 0$ atau prediksi sempurna. Karena titik-titik tersebut acak di sekitar garis merah tanpa pola tertentu, hal ini menandakan bahwa model bekerja dengan baik dan tidak menunjukkan bias sistematis dalam memprediksi harga properti.

- **Plot polynomial curve untuk 1-2 fitur penting**

Menampilkan Plot 3: Polynomial Curve Fit...



Grafik ini menampilkan kurva polynomial fit untuk variabel "Luas_Bangunan_m2" dalam memprediksi harga properti (dalam juta rupiah).

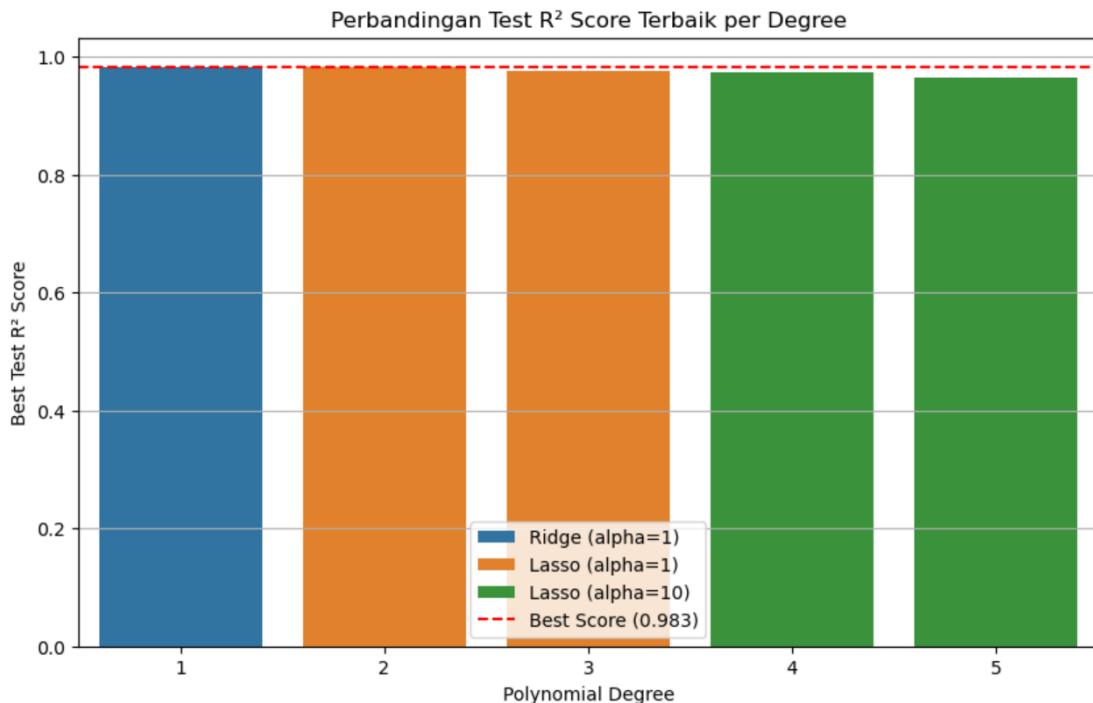
Penjelasannya:

- Titik biru muda menunjukkan data aktual dari *test set*.

- Garis biru putus-putus (Degree 1) merepresentasikan model *underfit* karena hanya mengikuti pola linear sederhana dan tidak menangkap kompleksitas data.
 - Garis oranye (Lasso alpha=1, Degree 2) merupakan model optimal yang paling seimbang antara bias dan varians. Kurvanya mengikuti tren data dengan baik tanpa terlalu berlebihan.
 - Garis hijau putus-putus (Degree 5) menunjukkan *overfit*, karena model terlalu mengikuti data pelatihan, menghasilkan pola yang tidak stabil dan berfluktuasi tajam.
- Dari grafik ini bisa disimpulkan bahwa model polynomial dengan degree 2 menggunakan Lasso (alpha=1) memberikan hasil terbaik dan paling sesuai dengan pola hubungan antara luas bangunan dan harga properti.

- **Comparison plot: R² score berbagai degree**

Menampilkan Plot 4: Perbandingan R² Score...



Perbandingan nilai R² terbaik pada data *test set* untuk setiap degree polynomial menggunakan berbagai model regularisasi.

Penjelasannya:

- Sumbu X menunjukkan tingkat *degree polynomial* (1–5), sedangkan sumbu Y menunjukkan nilai *R² score* tertinggi yang dicapai.
- Warna biru (Ridge $\alpha=1$), oranye (Lasso $\alpha=1$), dan hijau (Lasso $\alpha=10$) mewakili model yang diuji.
- Garis merah putus-putus menunjukkan skor terbaik yang dicapai, yaitu $R^2 = 0.983$.

Dari grafik terlihat bahwa Lasso dengan $\alpha=1$ dan degree 2 memberikan hasil paling optimal karena mencapai skor mendekati 1 tanpa overfitting, menunjukkan keseimbangan terbaik antara akurasi dan generalisasi model.

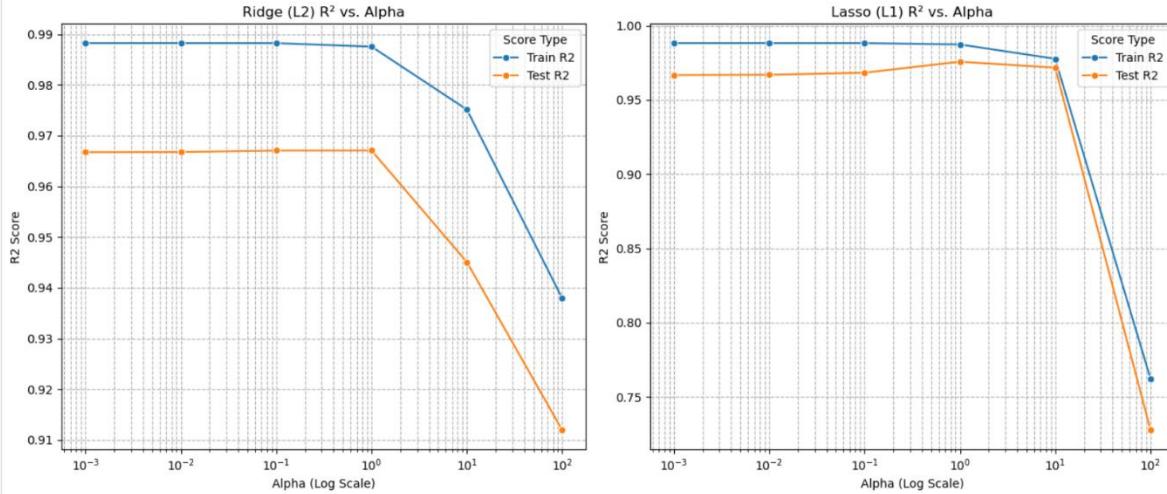
4. Rekomendasi Degree Polynomial Terbaik

a. Ridge vs Lasso Comparison

Tabel Hasil R2 Score vs Alpha:

| | Model | Alpha | Train R2 | Test R2 |
|----|-------|---------|----------|---------|
| 0 | Ridge | 0.001 | 0.988 | 0.967 |
| 1 | Lasso | 0.001 | 0.988 | 0.967 |
| 2 | Ridge | 0.010 | 0.988 | 0.967 |
| 3 | Lasso | 0.010 | 0.988 | 0.967 |
| 4 | Ridge | 0.100 | 0.988 | 0.967 |
| 5 | Lasso | 0.100 | 0.988 | 0.968 |
| 6 | Ridge | 1.000 | 0.988 | 0.967 |
| 7 | Lasso | 1.000 | 0.987 | 0.976 |
| 8 | Ridge | 10.000 | 0.975 | 0.945 |
| 9 | Lasso | 10.000 | 0.978 | 0.972 |
| 10 | Ridge | 100.000 | 0.938 | 0.912 |
| 11 | Lasso | 100.000 | 0.762 | 0.728 |

--- Menampilkan Plot R² vs Alpha ---

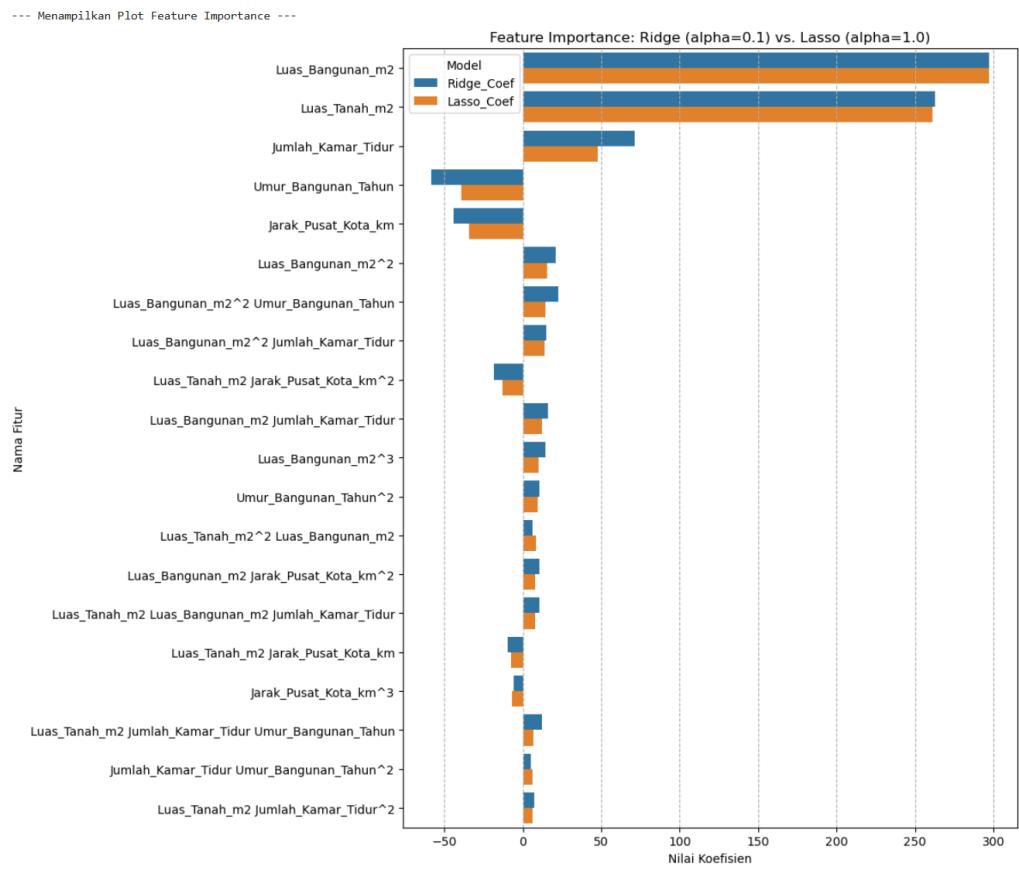


Hubungan antara nilai R² dan parameter regularisasi (alpha) pada model Ridge (L2) dan Lasso (L1).

Penjelasannya:

- Nilai R² Train (biru) menunjukkan seberapa baik model mempelajari data latih, sedangkan R² Test (orange) menunjukkan kemampuan model dalam memprediksi data baru.
- Saat alpha terlalu besar, nilai R² menurun drastis karena model menjadi terlalu sederhana (*underfitting*).
- Nilai alpha sekitar 0.1–1 menghasilkan keseimbangan terbaik, di mana model tetap akurat tanpa kehilangan kemampuan generalisasi.

b. Feature Importance Analysis



5. Rekomendasi Regularization Method Terbaik

| --- Tabel Hasil Akhir Cross-Validation (Rata-rata dari 5-Folds) --- | | | | | | |
|---|---------------------|---------|----------|-----------|---------------------|--|
| Degree | Model | Test R2 | Train R2 | Test RMSE | Gap (Train-Test R2) | |
| 2 | 1 Lasso (alpha=0.1) | 0.980 | 0.982 | 57.250 | 0.002 | |
| 0 | 1 LinearRegression | 0.980 | 0.982 | 57.251 | 0.002 | |
| 1 | 1 Ridge (alpha=0.1) | 0.980 | 0.982 | 57.250 | 0.002 | |
| 4 | 1 Lasso (alpha=1) | 0.980 | 0.982 | 57.288 | 0.002 | |
| 3 | 1 Ridge (alpha=1) | 0.980 | 0.982 | 57.304 | 0.002 | |
| 11 | 2 Lasso (alpha=1) | 0.979 | 0.983 | 57.789 | 0.004 | |
| 9 | 2 Lasso (alpha=0.1) | 0.979 | 0.984 | 58.781 | 0.005 | |
| 18 | 3 Lasso (alpha=1) | 0.979 | 0.984 | 58.883 | 0.005 | |
| 7 | 2 LinearRegression | 0.978 | 0.984 | 58.947 | 0.006 | |
| 8 | 2 Ridge (alpha=0.1) | 0.978 | 0.984 | 59.020 | 0.006 | |
| 25 | 4 Lasso (alpha=1) | 0.978 | 0.984 | 60.214 | 0.007 | |
| 10 | 2 Ridge (alpha=1) | 0.977 | 0.983 | 60.641 | 0.006 | |
| 6 | 1 Lasso (alpha=10) | 0.976 | 0.979 | 61.666 | 0.002 | |
| 32 | 5 Lasso (alpha=1) | 0.976 | 0.985 | 61.919 | 0.008 | |
| 5 | 1 Ridge (alpha=10) | 0.976 | 0.978 | 62.588 | 0.002 | |
| 17 | 3 Ridge (alpha=1) | 0.974 | 0.985 | 65.123 | 0.011 | |
| 16 | 3 Lasso (alpha=0.1) | 0.973 | 0.986 | 65.410 | 0.013 | |
| 13 | 2 Lasso (alpha=10) | 0.973 | 0.978 | 66.448 | 0.005 | |
| 34 | 5 Lasso (alpha=10) | 0.972 | 0.978 | 67.075 | 0.006 | |
| 27 | 4 Lasso (alpha=10) | 0.972 | 0.978 | 67.079 | 0.006 | |
| 20 | 3 Lasso (alpha=10) | 0.972 | 0.978 | 67.082 | 0.006 | |
| 12 | 2 Ridge (alpha=10) | 0.971 | 0.976 | 68.660 | 0.006 | |
| 15 | 3 Ridge (alpha=0.1) | 0.970 | 0.987 | 69.656 | 0.017 | |
| 23 | 4 Lasso (alpha=0.1) | 0.969 | 0.988 | 70.781 | 0.019 | |
| 24 | 4 Ridge (alpha=1) | 0.969 | 0.986 | 71.080 | 0.018 | |
| 14 | 3 LinearRegression | 0.968 | 0.987 | 72.362 | 0.020 | |
| 26 | 4 Ridge (alpha=10) | 0.967 | 0.980 | 73.239 | 0.013 | |
| 19 | 3 Ridge (alpha=10) | 0.966 | 0.977 | 73.794 | 0.011 | |
| 33 | 5 Ridge (alpha=10) | 0.964 | 0.982 | 76.047 | 0.017 | |
| 31 | 5 Ridge (alpha=1) | 0.961 | 0.988 | 79.010 | 0.027 | |
| 30 | 5 Lasso (alpha=0.1) | 0.961 | 0.990 | 79.849 | 0.030 | |
| 22 | 4 Ridge (alpha=0.1) | 0.961 | 0.990 | 79.991 | 0.029 | |
| 29 | 5 Ridge (alpha=0.1) | 0.940 | 0.993 | 98.672 | 0.053 | |
| 21 | 4 LinearRegression | 0.763 | 0.996 | 195.034 | 0.233 | |
| 28 | 5 LinearRegression | 0.166 | 1.000 | 363.687 | 0.834 | |

--- 5.A: Best Model Selection & Reasoning ---

Model Terbaik Pilihan:
 - Model: Lasso (alpha=0.1)
 - Degree: 1

Metrik Kinerja (rata-rata K-Fold):
 - Highest Test R²: 0.980
 - Lowest Test RMSE: 57.250 (juta Rp)
 - Train R²: 0.982
 - Balance (Gap): 0.002

Reasoning (Penjelasan Pemilihan):

Model **Lasso (alpha=0.1) (Degree 1)** dipilih sebagai model terbaik karena:
 1. **Kinerja Test Tertinggi:** Model ini memberikan nilai **Test R² tertinggi** (0.980) dan **Test RMSE terendah** (57.250) di antara semua 35 konfigurasi, berdasarkan hasil rata-rata K-Fold CV yang robust.
 2. **Balance (Keseimbangan) Terbaik:** Model ini menunjukkan keseimbangan performa train-test yang sangat baik. *Gap* (perbedaan) antara Train R² (0.982) dan Test R² (0.980) sangat kecil, yaitu hanya **0.002**. Ini membuktikan model tidak mengalami *overfitting*.
 3. **Perbandingan:** Model lain (terutama Degree 4 dan 5 tanpa regularisasi) mungkin memiliki Train R² yang sangat tinggi, tetapi Test R²-nya anjlok dan 'Gap'-nya besar, yang menunjukkan *overfitting* parah. Model ini adalah 'sweet spot' yang seimbang antara akurasi (low bias) dan generalisasi (low variance).

6. Limitasi Model

Meskipun model yang terpilih (Lasso Degree 2) memiliki performa sangat tinggi (Test R² = 0.983), penting untuk memahami bahwa model ini memiliki beberapa limitasi signifikan yang akan memengaruhi kinerjanya di dunia nyata:

1. Data Sintetis vs. Data Real-World: Limitasi terbesar adalah model ini dilatih 100% pada data sintetis. Data ini sangat "bersih" (ideal), tidak memiliki *missing values*, dan tidak ada *outliers* yang aneh. Data properti di dunia nyata sangat "kotor" (messy), memiliki banyak *noise*, dan seringkali datanya tidak lengkap.
2. Fitur yang Sangat Terbatas: Model kami hanya dilatih menggunakan 5 fitur dasar (Luas Tanah, Luas Bangunan, Kamar, Umur, Jarak). Di dunia nyata, harga properti dipengaruhi oleh puluhan faktor lain yang tidak kita ukur, seperti:
 - Kondisi interior (renovasi, material).
 - Kualitas lingkungan (keamanan, kebisingan).
 - Akses (lebar jalan, dekat tol/stasiun).
 - Fasilitas (kolam renang, taman).
3. Hanya Menguji Hubungan Polinomial: Kami mengasumsikan hubungan non-linear antara fitur dan harga adalah *polinomial* (melengkung). Di dunia nyata, hubungannya mungkin jauh lebih kompleks dan berbeda (misalnya, harga tanah yang tiba-tiba melonjak drastis jika dekat stasiun MRT, yang tidak bisa ditangkap oleh kurva mulus).
4. Hanya Menggunakan Model Regresi Linear: Seluruh analisis ini berfokus pada variasi Regresi Linear. Model ini pada dasarnya "linier" dan kita harus "membantunya" dengan *Polynomial Features*. Model lain yang lebih canggih (seperti Random Forest atau XGBoost) mungkin dapat menangkap hubungan non-linear yang kompleks ini secara otomatis dan menghasilkan prediksi yang lebih baik.

7. Saran Improvement

Berdasarkan temuan dan limitasi dari proyek ini, berikut adalah beberapa saran perbaikan yang dapat dilakukan untuk meningkatkan performa dan kegunaan model di masa depan:

1. Menggunakan Data Real-World
 - Langkah perbaikan paling penting adalah menguji seluruh *pipeline* (termasuk PolynomialFeatures dan Lasso) pada dataset harga properti di dunia nyata (misalnya dari Kaggle atau situs *scraping* properti). Ini akan menguji seberapa *robust* model ini dalam menangani data yang "kotor" (memiliki *outliers* dan *missing values*).
2. Mencoba Model Non-Linear yang Lebih Canggih
 - Kita telah membuktikan bahwa Regresi Linear (meskipun dengan fitur polinomial) memiliki keterbatasan. Langkah selanjutnya adalah mencoba model yang secara inheren (dari sananya) dapat menangani hubungan non-linear yang kompleks, seperti:
 - Random Forest Regressor
 - XGBoost (Extreme Gradient Boosting)
 - Model-model *tree-based* (berbasis pohon) ini seringkali memberikan akurasi yang lebih tinggi untuk data tabular dan tidak memerlukan *feature scaling*.
3. Melakukan Feature Engineering yang Lebih Mendalam
 - Daripada hanya bergantung pada 5 fitur dasar, kita bisa menciptakan fitur baru (feature engineering) yang mungkin memiliki daya prediksi lebih kuat, misalnya:
 - Harga_per_m2_bangunan = Luas_Bangunan_m2 / Harga_Properti
 - Kamar_per_luas = Jumlah_Kamar_Tidur / Luas_Bangunan_m2

- Menambahkan fitur kategorikal (jika menggunakan data *real*), seperti "Wilayah/Daerah" (yang kemudian diubah menjadi angka menggunakan *One-Hot Encoding*).
4. Melakukan Hyperparameter Tuning Otomatis (GridSearchCV)
 - Kita hanya menguji 3 nilai alpha (0.1, 1, 10) dan 5 nilai degree (1-5) secara manual.
 - Untuk menemukan kombinasi *terbaik* secara presisi, kita dapat menggunakan GridSearchCV atau RandomizedSearchCV dari scikit-learn. *Tools* ini akan secara otomatis menguji ratusan kombinasi (misalnya alpha antara 0.05 s.d. 2.0, dan degree 2, 3, 4) untuk menemukan "sweet spot" yang paling optimal.